Partie 2 : calcul sur GPU

Exercice 1 Première prise en main des GPU. Tous les fichiers mentionnés sont disponibles sur moodle.

1. Récupérer le fichier `example1.cu`, compiler le avec nvcc et exécuter le programme généré.
2. Récupérer le fichier `deviceQuery.cpp` et compiler le avec nvcc. Attention, il vous faudra ajouter l'option de compilation `-I/usr/local/cuda-11.5/samples/common/inc`. Exécuter le programme généré et regarder les caractéristiques CUDA de votre carte graphique (taille des grilles, taille des blocs, nombre maximal de threads par bloc, ...).
3. Récupérer le fichier `example2.cu` et compiler le avec nvcc. Lors de son exécution ce programme doit afficher les entiers de 0 à 9. Lancer l'utilitaire `cuda-memcheck` pour vérifier votre programme (`cuda-memcheck` ./monprog). Recompiler votre fichier en ajoutant les options de compilation `-Xcompiler -rdynamic -lineinfo`. Relancer `cuda-memcheck` et corriger le kernel GPU.

Exercice 2 On souhaite implanter un kernel CUDA pour faire le calcul sur GPU de la somme de deux vecteurs de taille n contenant des `float`. Notre kernel exécutera au moins n threads qui s'occuperont de calculer une entrée du résultat.
Nous allons considérer que notre kernel sera exécuté sur une grille et des blocs ayant une seule dimension car il n'y a pas lieu à utiliser de dimension supérieure. La règle avec les architecture CUDA est que le nombre de threads dans un bloc doit être un multiple de 32 (la taille d'un *warp*). Nous allons dans un premier temps nous intéresser à déterminer quelles sont les paramètres possibles d'exécution de notre kernel CUDA.

1. Donner l'ensemble des configurations possibles pour les tailles de grille et de blocs pour des vecteurs de taille $1024, 1023$ et 1025.
2. Quelle est la taille de grille lorsqu'on souhaite des blocs de taille 128 avec des vecteurs de taille n ?
3. Caractériser les valeurs de n pour lesquelles notre kernel laissera des threads inactifs ?

Nous allons maintenant programmer et exécuter ce kernel.

5. Compléter le kernel ci-dessous pour qu'il fasse l'addition sur GPU de vecteur de `float` ($C = A+B$). Pour rappel : chaque entrée du résultat doit être calculée par un thread différent (le nombre de thread lancé sera $\geq n$) ; on peut récupérer l'indice d'un thread dans un bloc au travers de la variable globale `threadIdx`, l'indice du bloc au travers de la variable globale `blockIdx` et la taille du bloc au travers de la variable globale `blockDim`. **Attention** : chacune de ces variables contient des attributs `x`, `y` et `z` pour récupérer la valeur de la dimension concernée ; il faudra également tenir compte que certains threads ne serviront à rien.

```
__global__ void vectorAddition(float* C, const float* A, const float* B, size_t n){
  ...
}
```

6. Écrire une fonction classique en C++ qui fait le calcul de la somme de deux vecteur de float (sans CUDA). Écrire un programme qui génère deux tableaux hA et hB contenant n flottants initialisés avec des valeurs entières aléatoires entre 0 et 65535 et qui calcule leur somme dans un vecteur hC. La valeur de n doit être passé comme paramètre du programme.
7. Dans ce même programme, utiliser les fonction `cudaMalloc, cudaMemcopy, cudaFree` pour préparer l'exécution de votre kernel sur les données stockées dans hA et hB.
8. Utiliser votre kernel pour faire le calcul et comparer le résultat avec le vecteur hC obtenu par l'appel de votre fonction CPU (Attention, il y a de nombreuses copies de données à effectuer). Vous essaierez l'ensemble des configurations possibles de lancement de votre kernel en supposant que la taille des blocs et un multiple de 32.
9. En vous inspirant de l'addition de vecteur, proposer une nouveau kernel qui permet de faire l'addition de deux matrices stockées au format *RowMajor*, cf signature ci-dessous. Vous ferez comme précédemment en définissant une fonction CPU qui fait le même calcul et vous vérifierez que les résultats sont identiques. Pour ce kernel vous devrez utiliser une grille et des blocs en deux dimensions. Vous testerez votre kernel sur quelques configurations pertinentes (petite grille + grand bloc, moyenne grille+moyen bloc, grande grille + petit blocs).

10. Comparez les performances de vos kernels GPU et des fonctions CPU équivalente. Pour cela, vous utiliserez votre classe `EvalPerf`. Attention, le lancement d'un kernel étant asynchrone, il faudra que l'appel à votre kernel soit suivi de l'instruction `cudaDeviceSynchronize();` pour que le temps d'exécution soit correct.

Exercice 3 Nous souhaitons écrire un traitement d'image simple sur GPU. Pour cela, nous allons nous intéresser à un filtre moyenneur qui permet de flouter une image. Le principe du filtre moyenneur consiste à remplacer un pixel donné par la moyenne des valeurs des pixels qui l'entoure. La notion d'entourage est relié à la taille du filtre. Pour faire simple, nous considérerons un filtre de taille $2B+1$ de telle sorte que la valeur d'un pixel $P_{x,y}$ à la position (x, y) sera remplacé par

$$\frac{1}{(2B+1)^2} \sum_{i=x-B}^{x+B} \sum_{j=y-B}^{y+B} P_{i,j}$$

L'image ci-dessous illustre le concept de ce filtre pour $B = 1$.

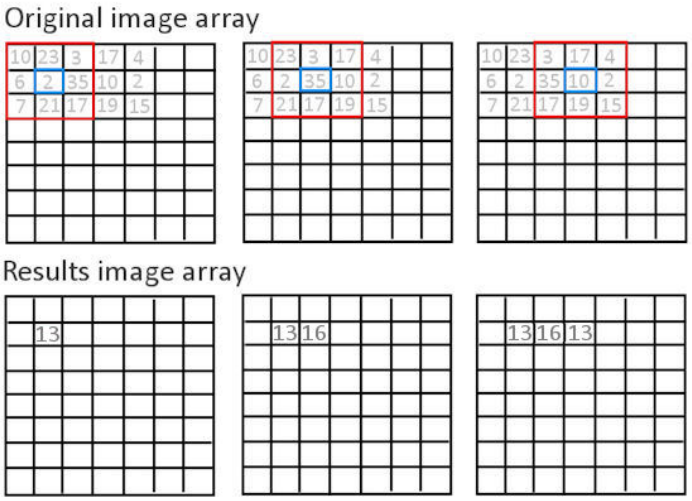

Bien entendu, pour les pixels en bordure la taille du filtre s'adaptera pour ne contenir que les pixels existants. Autrement dit, on ne considère que les voisins existants du pixel $P_{x,y}$ qui sont à une distance maximale de B en abscisse et en ordonnée.
Pour vous simplifier la gestion de la lecture/écriture de fichier d'image, vous trouverez sur l'ENT un fichier `image-pnm.h` qui vous fournit une classe `Image`. Cette dernière permet de manipuler des images au format PNM ASCII : PBM (encodage monochrome avec pixel noir ou blanc), PGM (encodage monochrome avec 256 niveau de gris) et PPM (encodage couleur RGB avec 256 niveau de couleur par canal). Vous trouverez également un fichier d'exemple `copy-image.cpp` qui crée une copie d'une image à l'un des formats supporté.

1. Écrire une fonction `blur_pbm` qui permet d'appliquer un filtre moyenneur sur une image. Pour vous simplifier la tâche votre fonction sera de type `void` et prendra en paramètre une image source et une image cible. Seule l'image cible sera modifiée. Vous utiliserez un paramètre global pour définir la valeur de B dans la taille du filtre moyenneur (par exemple B=4).
2. En vous inspirant de votre code précédent, proposer un kernel GPU qui fait la même tâche. ATTENTION, ce kernel ne devra pas manipuler la classe image, par conséquent votre kernel devra avoir la signature suivante :
   `__global__ blur_pbm_kernel(uint8_t *ImgOut, const uint8_t* imgIn, int width, int height);`
3. En vous inspirant du fichier d'exemple `copy-image.cpp`, écrire un fichier CUDA (`blur-image.cu`) qui permet de lire un fichier image au format PBM et qui génère un nouveau fichier au format PBM dans lequel le filtre moyenneur a été appliqué. Vous trouverez des images sur l'ENT pour tester votre programme.
4. Évaluer les performances de vos codes et essayer de trouver de manière empirique quelle est la meilleure configuration de lancement de votre kernel GPU.
5. À votre convenance, proposer un autre kernel de traitement d'image et tester le sur les images proposées. Si vous n'avez pas d'idée, vous pouvez soit faire un kernel de passage d'une image

couleur en une image à niveau de gris, soit faire une rotation de 180 degrés, soit un flip horizontal de l'image.

Exercice 4 Nous allons reprendre vos codes de produit de matrices et voir si vous êtes capable d'être plus rapide avec des calculs sur GPU.
Le principe d'un produit de matrice « naïf » sur GPU est que chaque thread s'occupe de calculer une unique entrée de la matrice résultat. Si l'on multiplie des matrices carrées de dimension n, cela implique donc de lancer au moins n^2 threads. Pour coller au plus près avec les matrices, nous considérerons que notre kernel utiliser des grilles et des blocs deux dimensions.

1. Écrire un kernel GPU qui calcule un produit de matrice carrée contenant des float. Bien entendu, ce kernel doit prendre en compte que certains thread ne feront aucun calcul.
2. Modifier votre programme pour qu'il puisse exécuter en plus de vos fonctions CPU, ce nouveau kernel GPU. Vous comparerez les performances de vos codes sur des matrices aléatoires de taille 2^k pour k allant de 8 à 12. Vous essaierez de trouver de manière empirique quel est le meilleur choix pour le nombre de threads par bloc.

Afin d'améliorer les performances de votre kernel GPU de multiplication de matrices vous allez utiliser la mémoire partagé au sein des blocs (la *shared memory*). Pour rappel, afin de déclarer ce type de mémoire, il faut préfixer vos allocations avec le mot clé `__shared__`. Attention, par défaut les allocations en *shared memory* doivent être statique. Ex : `__shared__ int T[4];` Si vous désirez utiliser de la mémoire dynamique il vous faudra gérer vous même le partage de cette mémoire car c'est au lancement du kernel qu'on précise la taille de la mémoire dynamique au sein d'une SM. Pour cela, il vous faudra renseigner un 3ème paramètre au lancement du kernel qui correspond à la taille en octet de la mémoire dynamique par bloc (donc par SM). Pour accéder à cette mémoire dans les blocs il faudra déclarer la variable `extern __shared__ int smem[];` qui recevra l'adresse de la mémoire dynamique.

4. En reprenant la méthode du multiplication de matrices par bloc vu en cours, implanter cette algorithme en utilisant la mémoire partagée. Pour faire simple, la taille des blocs de matrices correspondra à la taille des blocs GPU. Pour chacun des blocs GPU il faudra charger de manière synchronisée les données provenant des matrices d'entrée dans la *shared memory*. Pour synchroniser les threads d'un bloc GPU il vous faut utiliser l'instruction `__syncthreads();` dans votre kernel. Une fois que toutes les données des deux blocs de matrices des entrées sont copiées dans la *shared memory* du bloc GPU, chaque thread du bloc va s'occuper de calculer une entrée de la sortie, en lisant uniquement les données de la *shared memory*.
5. Comparer les performances de vos kernel GPU avec et sans utilisation de la *shared memory*

Exercice 5 Dans le même esprit, nous allons reprendre votre code de kernel GPU pour l'application d'un filtre moyenneur sur une image. L'idée est d'essayer d'optimiser les accès mémoires au sein d'un bloc de threads en utilisant la mémoire partagée. En effet, si l'on regarde les chargements de données fait par votre kernel, chaque thread va lire dans la mémoire globale du GPU $(2B+1)^2$ données. Hors si on regarde les threads de coordonnées (x, y) et $(x+1, y)$ au sein d'un même bloc, ils ont $(2B+1)^2 - 2(2B+1) = 4B^2+1$ pixels en commun. Il est donc intéressant de stocker ces pixels dans de la *shared memory* pour éviter de multiplier les lectures de données identiques dans la mémoire globale du GPU qui est très lente.
Une des difficultés de cette optimisation est que l'ensemble des pixels d'un bloc de thread de taille $N \times N$ implique de récupérer $(N+2B)\times(N+2B)$ pixels de l'image initiale. En effet, à chaque pixel de coordonnées (x, y) on doit prendre en considération les pixels de coordonnées (p_x, p_y) avec $x - B \leq p_x \leq x + B$ et $y - B \leq p_y \leq y + B$. Par définition d'un bloc on a $0leqx, y < N$, ce qui implique que le nombre de pixel nécessaire est bien $(N + 2B)^2$. Par conséquent il faut équilibre la charge de N^2 threads dans un bloc pour charger $(N + 2B)^2$ données dans la mémoire partagée. De plus, il faudra faire attention de bien rajouter des 0 si les pixels ont des coordonnées en dehors des limites de l'image.

1. Proposer un nouveau kernel GPU optimisé avec de la mémoire partagé pour appliquer un filtre moyenneur sur une image.
2. Si vous avez écrit un code de convolution d'image à partir d'un filtre, vous pouvez également l'optimiser en déclarant la matrice de votre filtre dans de la mémoire globale constante du GPU `__device__ __constant__ int Filtre[2*B+1][2*B+1];`

Exercice 6 Si il vous reste du temps et de l'énergie, essayer d'optimiser votre code de tri par comptage en utilisant le GPU. Attention, pour que votre kernel soit efficace, il faudra utiliser de la mémoire partagé et des opérations atomiques.